

Projet 8 : Réalisez un traitement dans un environnement Big Data sur le Cloud

Presented by Kourouma Sekouba

PLAN DE LA PRESENTATION

1. **PROBLÉMATIQUE ET PRÉSENTATION DU JEU DE DONNÉES**
2. **LE BIG DATA**
3. **CONCEPTION, CHAÎNE DE TRAITEMENT ET EXÉCUTION DU SCRIPT PYSPARK SUR LE CLOUD**
4. **CONCLUSION**

1. PROBLÉMATIQUE ET PRÉSENTATION DU JEU DE DONNÉES

1.1 Mission

La start-up "Fruits" Agri-Tech souhaite développer une application mobile capable d'identifier des fruits à partir de photos.

Objectif

- Traitement dans un environnement Big Data sur le Cloud
- Préserver la biodiversité des fruits
- Utilisation de robots cueilleurs intelligents
Pour récolter les fruits



Comment gérer l'évolution rapide du volume de données dans l'architecture Big Data ?

Quels sont les défis liés à la mise en œuvre d'un système de robots cueilleurs intelligents ?

Comment garantir la confidentialité et la sécurité des données dans le respect des contraintes RGPD ?

1.2 PRÉSENTATION DU JEU DE DONNÉES

<https://www.kaggle.com/datasets/moltean/fruits>

Le jeu de données **Fruits-360** est une vaste collection d'images dédiée à la classification et à l'identification

Caractéristiques principales

- **94 110** images réparties entre des ensembles d'entraînement et de test
- Ces images représentent un unique objet par image.

Nombre de classes :

- **141** catégories, incluant différentes variétés de fruits, légumes et noix. Par exemple, plusieurs variétés de pommes (**Golden, Pink Lady, Granny Smith**)

Taille des ensembles :

- Entraînement : **70 491** images.
- Test : **23 619** images.

kaggle



Golden
Delicious



Red Delicious



Granny Smith

Taille des images :

- échelle à **100x100 pixels** pour un traitement rapide.
- capturés dans un studio avec un fond blanc

2. LE BIG DATA

Ensembles de données massifs, complexes et diversifiés qui ne peuvent pas être traités efficacement à l'aide des méthodes traditionnelles de gestion de données.



Les trois caractéristiques fondamentales du Big Data sont souvent décrites par les 3V:

- **Volume** : Quantité massive de données produites chaque seconde (gigaoctets, téraoctets, voire pétaoctets).
- **Vitesse** : Rapidité à laquelle les données sont générées.
- **Variété** : Différents types de données (structurées, semi-structurées et non structurées).

2.1 Outils et frameworks Big Data

Le Big Data repose sur des outils et technologies permettant de gérer et de traiter efficacement des volumes massifs de données.

Calculs distribués: Il consiste à répartir le stockage et le traitement des données sur plusieurs unités de calcul (serveurs ou nœuds) connectées en clusters.

Cela permet :

- Gain de temps
- Évolutivité
- Tolérance aux pannes

Apache Spark: est un framework open-source conçu pour le traitement de données massives en utilisant le calcul distribué in-memory (en mémoire vive), ce qui accélère les performances.

Algorithme MapReduce: est un modèle de programmation distribué, largement utilisé pour traiter et analyser de grandes quantités de données.

- **MAP :** les données sont divisées en ensembles plus petits, traitées de manière indépendante par plusieurs nœuds.
- **REDUCE :** les résultats des opérations MAP sont agrégés pour produire un résultat final.

2.2. CRÉATION DE L'ENVIRONNEMENT BIG DATA SUR LE CLOUD

2.1 Environnement Techniques

- Foxyproxy



- Python



- PySpark



- TensorFlow




- AWS (Amazon Web Services)



- JupyterHub




- PuTTY



2.3 Architecture Big data avec AWS

Le cloud, en particulier des fournisseurs comme AWS, facilite considérablement le déploiement de solutions Big Data en offrant une infrastructure scalable et des services managés.



Simple Storage Service



Identity and Access Management



Elastic MapReduce



2.4 Configuration EMR-AWS

2.4.1 Nom et applications - requis

Cloner « projet-8-sekou-cluster1 » [Info](#)

▼ **Nom et applications - requis** [Info](#)
Donnez un nom à votre cluster et choisissez les applications que vous voulez y installer.

Nom
projet-8-sekou-cluster1

Version Amazon EMR [Info](#)
Une version contient un ensemble d'applications susceptibles d'être installées sur votre cluster.
emr-6.13.0

Offre d'applications

Spark	Core Hadoop	Flink	HBase	Presto	Trino	Custom
						

☐ Flink 1.17.0
☐ HCatalog 3.1.3
☐ Hue 4.11.0
☐ Livy 0.7.1
☐ Phoenix 5.1.3
☒ Spark 3.4.1
☐ Tez 0.10.2
☐ ZooKeeper 3.5.10

☐ Ganglia 3.7.2
☒ Hadoop 3.3.3
☐ JupyterEnterpriseGateway 2.6.0
☐ MXNet 1.9.1
☐ Pig 0.17.0
☐ Sqoop 1.4.7
☐ Trino 414

☐ HBase 2.4.17
☐ Hive 3.1.3
☒ JupyterHub 1.5.0
☐ Oozie 5.2.1
☐ Presto 0.281
☒ TensorFlow 2.11.0
☐ Zeppelin 0.10.1

Paramètres du catalogue de données AWS Glue
Utilisez le catalogue de données AWS Glue pour fournir un metastore externe à votre application.
☐ Utiliser pour les métadonnées de table Spark

Options du système d'exploitation [Info](#)
☒ Version Amazon Linux :
☐ Amazon Machine Image (AMI) personnalisée
☒ Appliquez automatiquement les dernières mises à jour Amazon Linux

- **Hadoop** : gestion du stockage et du traitement distribué des données.
- **Spark** : exécution des calculs distribués sur les données traitées par Hadoop
- **TensorFlow** : chargement du modèle et application de l'apprentissage par transfert
- **JupyterHub** : exécution des scripts PySpark directement depuis le Notebook.

2.4.2 Configuration de cluster

Cette section traite de la configuration des groupes de nœuds de notre cluster, en mettant l'accent sur les options de provisionnement des instances EC2.

▼ Configuration de cluster - *requis* [Info](#)

Choisissez une méthode de configuration pour les groupes de nœuds primaires, principaux et de tâches de votre cluster.

☒ **Groupes d'instances uniformes**
Choisissez le même type d'instance EC2 et la même option d'achat (à la demande ou Spot) pour tous les nœuds de votre groupe de nœuds. [En savoir plus](#)

☐ **Flottes d'instances flexibles**
Choisissez parmi la plus grande variété d'options de provisionnement pour les instances EC2 de votre cluster. Diversifiez les types d'instances et les options d'achat, et utilisez une stratégie d'allocation. [En savoir plus](#)

Groupes d'instances uniformes

Primaire

Choisir un type d'instance EC2

m5.xlarge
4 vCore 16 GiB mémoire
EBS uniquement stockage
Prix à la demande : 0.224 USD par insta...
Prix Spot le plus bas : 0.079 USD (eu-west...)

Actions ▼

☐ **Utiliser la haute disponibilité**
Lancez des clusters hautement disponibles et plus résilients avec trois nœuds primaires sur des instances à la demande. Cette configuration s'applique pendant toute la durée de vie de votre cluster. [En savoir plus](#)

► Configuration de nœud - *facultatif*

Unité principale

Choisir un type d'instance EC2

m5.xlarge
4 vCore 16 GiB mémoire
EBS uniquement stockage
Prix à la demande : 0.224 USD par insta...
Prix Spot le plus bas : 0.079 USD (eu-west...)

Actions ▼

► Configuration de nœud - *facultatif*

Méthode de provisionnement pour les groupes de nœuds (primaires, principaux et de tâches):

- **Groupes d'instances uniformes:** Tous les nœuds d'un groupe utilisent le même type d'instance EC2 et la même option d'achat.
- **Flottes d'instances flexibles:** choix d'une grande variété de types d'instances EC2 et d'options d'achat

Choix opté pour le groupes d'instances uniformes.

Groupes d'instances uniformes:

- **Nœud primaire** : Gère et coordonne le cluster.
- **Nœuds principaux** : Réalisent le traitement des données.
- **Nœuds de tâches** : Exécutent les processus parallèles pour augmenter la capacité de calcul.

Stockage EBS (Elastic Block Store):

- Il fournit des volumes de stockage durables et hautement disponibles, qui peuvent être attachés aux instances EC2.
- agit comme un disque dur virtuel pour les instances EC2.

2.4.3 Dimensionnement et Mise en Service du Cluster

Nous avons choisi de définir manuellement la taille du cluster afin d'optimiser les coûts.

- **Définir manuellement la taille du cluster:** Permet de spécifier directement le nombre et le type de nœuds.

Mise à l'échelle gérée par EMR: Amazon EMR surveille automatiquement les métriques clés et ajuste dynamiquement la taille du cluster pour optimiser l'utilisation des ressources.

Autoscaling personnalisé: Permet de configurer des politiques d'autoscaling spécifiques pour ajuster le nombre de nœuds principaux et de tâches de manière programmatique en fonction des besoins précis.

▼ **Dimensionnement et mise en service du cluster - *requis*** Info

Choisissez la manière dont Amazon EMR doit dimensionner votre cluster.

Choisir une option

☒ **Définir manuellement la taille du cluster**
Utilisez cette option si vous connaissez vos modèles de charge de travail à l'avance.

☐ **Utiliser la mise à l'échelle gérée par EMR**
Surveillez les principales métriques de charges de travail afin qu'EMR puisse optimiser la taille du cluster et l'utilisation des ressources.

☐ **Utiliser un autoscaling personnalisée**
Pour dimensionner de manière programmatique les unités principales et les nœuds de tâches, créez des politiques d'autoscaling personnalisées.

Configuration de mise en service

Définissez la taille de votre noyau et tâchegroupes d'instance. Amazon EMR tente de fournir cette capacité lorsque vous lancez votre cluster.

Nom	Type d'instance	Taille de l'instance(s)	Utiliser l'option d'achat Spot
Tâche - 1	m5.xlarge	1	☐
Unité principale	m5.xlarge	2	☐

2.4.4 Réseaux - requis

Cette section explique comment configurer les paramètres réseau pour permettre une communication fluide entre notre EMR et d'autres entités.

▼ Réseaux - *requis* [Info](#)

Choisissez les paramètres réseau qui déterminent la façon dont vous et les autres entités communiquez avec votre cluster.

Cloud privé virtuel (VPC) [Info](#)

vpc-0cc0a0f41d0863d2f

Parcourir

Créer un VPC [↗](#)

Sous-réseau [Info](#)

subnet-04555a3099330d61f

Parcourir

Créer un sous-réseau [↗](#)

▼ Groupes de sécurité EC2 (pare-feu)

ⓘ Avis de modification

Nous avons mis à jour les noms de certaines groupes de sécurité afin d'utiliser un langage plus inclusif. Par exemple, les groupes qui incluaient des termes tels que « maître » et « esclave » utilisent désormais les termes « primaire » et « principal » à la place.

Nœud primaire

Groupe de sécurité géré EMR

EMR mettra automatiquement à jour le groupe sélectionné

ElasticMapReduce-Primary
sg-06ccef2bf03f863a1

Groupes de sécurité supplémentaires - *facultatif*

Sélectionnez jusqu'à 4 groupes de sécurité supplémentaires.

Choisir des groupes de sécurité supplémentaires ▼

Unités principales et nœuds de tâches

Groupe de sécurité géré EMR

EMR mettra automatiquement à jour le groupe sélectionné

ElasticMapReduce-Core
sg-0a5d04ced289c804f

Groupes de sécurité supplémentaires - *facultatif*

Sélectionnez jusqu'à 4 groupes de sécurité supplémentaires.

Choisir des groupes de sécurité supplémentaires ▼

- **Cloud Privé Virtuel (VPC):** Un réseau privé virtuel dédié dans lequel le cluster est déployé.
- **Sous-réseau:** Détermine l'emplacement dans le VPC où les ressources du cluster sont déployées.
- **Groupes de sécurité EC2 (pare-feu):** Contrôler le trafic entrant et sortant du cluster.

2.4.5 Résiliation du Cluster, Remplacement des Nœuds et Actions d'Amorçage

Cette section détaille les options de configuration pour la résiliation du cluster et la gestion des nœuds défectueux afin d'assurer une disponibilité continue et une protection contre les interruptions accidentelles.

▼ Résiliation du cluster et remplacement des nœuds [Info](#)

Choisissez des paramètres de résiliation et protégez votre cluster contre un arrêt accidentel.

Option de résiliation

☐ Résilier manuellement le cluster

☐ Résilier automatiquement le cluster à la fin de la dernière étape

☒ Résilier automatiquement le cluster après le temps d'inactivité (Recommandé)

Temps d'inactivité

Saisissez la durée avant la résiliation de votre cluster.

0 jour ▼

00:20:00

Choisissez une durée supérieure à 1 minute (00:01:00) et inférieure à 7 jours. L'heure est au format hh:mm:ss (24 heures).

☐ Utiliser la protection contre la résiliation

Protège votre cluster contre les résiliations accidentelles. Si cette option est activée, vous devez d'abord désactiver la protection pour résilier le cluster. Nous vous recommandons d'activer la protection contre la résiliation pour vos clusters de longue date.

Remplacement des nœuds défectueux - nouveau [Info](#)

☐ Activer

Amazon EMR interrompt les processus sur les nœuds défectueux afin de minimiser les pertes de données et les interruptions de travail. Il remplace rapidement ces nœuds défectueux par de nouvelles instances EC2 pour assurer le bon fonctionnement de vos tâches en cours d'exécution.

☒ Désactiver

Amazon EMR ajoute les nœuds défectueux à une liste de dénombrement tout en les conservant dans le cluster, ce qui vous permet de continuer à y accéder pour la résolution de problèmes.

▼ Actions d'amorçage (1) [Info](#)

Utilisez les actions d'amorçage pour installer des logiciels ou personnaliser la configuration de votre instance.

Nom

Emplacement Amazon S3 [?](#)

Arguments

☐ amorçage1

s3://projet-8-sekou/bootstrap.sh

-

Création d'un script d'amorçage :

- Un fichier nommé bootstrap-emr.sh est créé, contenant les commandes pip install nécessaires pour installer les bibliothèques manquantes.
- Chargement sur S3.
- Ajout du script aux actions d'amorçage.

```
File Edit Selection View Go Run Terminal Help
$ bootstrap.sh X
C: > Users > Utilisateur > Desktop > Réalisez un traitement dans un environnement Big Data sur le Cloud > $ bootstrap.sh
1  #!/bin/bash
2  sudo python3 -m pip install -U setuptools
3  sudo python3 -m pip install -U pip
4  sudo python3 -m pip install wheel
5  sudo python3 -m pip install pillow
6  sudo python3 -m pip install pandas==1.2.5
7  sudo python3 -m pip install pyarrow
8  sudo python3 -m pip install boto3
9  sudo python3 -m pip install s3fs
10 sudo python3 -m pip install fsspec
11
```

2.4.5 Paramètres du Logiciel et Configuration de Sécurité

Cette section couvre la personnalisation des configurations logicielles, ainsi que les paramètres de sécurité et d'accès pour le cluster.

- **Paire de ClésEC2** : Utilisée pour établir une connexion SSH sécurisée avec le cluster.
- **EMR_DefaultRole et EMR_EC2_DefaultRole**: Cette configuration garantit que le cluster dispose des rôles et profils IAM nécessaires pour interagir avec d'autres services AWS tout en maintenant un contrôle sécurisé sur les ressources du cluster.

▼ Paramètres du logiciel [Info](#)
Remplacez les configurations par défaut pour des applications spécifiques de votre cluster.

☒ Entrer la configuration ☐ Charger JSON à partir d'Amazon S3

```
1 {  
2   "Classification": "jupyter-s3-conf",  
3   "Properties": {  
4     "s3.persistence.bucket": "projet-8-sekou",  
5     "s3.persistence.enabled": "true"  
6   }  
7 }  
8 }  
9 }
```

JSON Ln 1, Col 1 ✖ : 0 ⚠ : 0

▼ Configuration de sécurité et paire de clés EC2 [Info](#)
Choisissez une configuration de sécurité ou créez-en une nouvelle que vous pourrez réutiliser avec d'autres clusters.

Configuration de sécurité
Sélectionnez les paramètres de chiffrement, d'authentification, d'autorisation et de service de métadonnées d'instance de votre cluster.

Paire de clés Amazon EC2 pour SSH sur le cluster [Info](#)

▼ Rôle Identity and Access Management (IAM) - *requis* [Info](#)
Choisissez ou créez une fonction du service et un profil d'instance pour les instances EC2 de votre cluster.

Fonction du service Amazon EMR [Info](#)
La fonction du service est un rôle IAM assumé par Amazon EMR pour mettre en service des ressources et effectuer des actions au niveau du service avec d'autres services AWS.

☒ Choisir une fonction du service existant
Sélectionnez une fonction du service par défaut ou un rôle personnalisé avec des stratégies IAM attachées afin que votre cluster puisse interagir avec d'autres services AWS.

☐ Créez une fonction du service
Laissez Amazon EMR créer une nouvelle fonction du service afin que vous puissiez accorder et restreindre l'accès aux ressources d'autres services AWS.

Fonction du service

Profil d'instance EC2 pour Amazon EMR
Le profil d'instance attribue un rôle à chaque instance EC2 d'un cluster. Le profil d'instance doit spécifier un rôle qui peut accéder aux ressources pour vos étapes et actions d'amorçage.

☒ Choisir un profil d'instance existant
Sélectionnez un rôle par défaut ou un profil d'instance personnalisé avec des stratégies IAM attachées afin que votre cluster puisse interagir avec vos ressources dans Amazon S3.

☐ Choisir un profil d'instance
Laissez Amazon EMR créer un profil d'instance afin de pouvoir spécifier un ensemble personnalisé de ressources auquel il peut accéder dans Amazon S3.

Profil d'instance



Rôle d'autoscaling personnalisé - facultatif
Lorsqu'une règle d'autoscaling personnalisée se déclenche, Amazon EMR assume ce rôle pour ajouter et résilier les instances EC2. [En savoir plus](#)

Rôle d'autoscaling personnalisé



2.4.6 Création du tunnel SSH à l'instance EC2

Une fois que le cluster atteint l'état "*En attente*" (*Waiting*)

Procédure pour établir une connexion sécurisée et accéder aux ressources du cluster en toute simplicité.




- Autorisez les connexions entrantes sur le port 22, qui correspond au port d'écoute du serveur SSH.
- Utilisez PuTTY pour établir un tunnel SSH vers le driver, afin de rediriger les requêtes via le port 8157.



3. CONCEPTION, CHAÎNE DE TRAITEMENT ET EXÉCUTION DU SCRIPT PYSPARK SUR LE CLOUD

Chargement des données

- Les données d'entrée, qui sont des images, sont organisées dans des répertoires représentant les labels et stockées dans le compartiment Amazon S3 spécifié.
- Nous utilisons Apache Spark pour charger les images au format binaire dans un DataFrame Spark.



Prétraitement des données (Preprocessing)

- Une nouvelle colonne, label, est ajoutée au DataFrame en extrayant les étiquettes à partir des noms de répertoires des fichiers dans le chemin S3.

Extraction de caractéristiques (features)

- Le modèle MobileNetV2, pré-entraîné sur le jeu de données ImageNet, est utilisé pour extraire des caractéristiques des images.
- Les poids du modèle sont diffusés à tous les nœuds Spark pour un traitement parallèle.
- Les images brutes sont redimensionnées, converties en tableau, et normalisées pour être compatibles avec MobileNetV2.
- Une UDF Spark est utilisée pour extraire les caractéristiques (vecteurs de caractéristiques) de chaque image en parallèle.

Réduction de dimensions et stockage des résultats

- Les vecteurs de caractéristiques, initialement sous forme de tableaux, ont été convertis en objets DenseVector compatibles avec la bibliothèque MLlib de PySpark.
- Les résultats finaux, incluant les chemins des images, leurs étiquettes, et leurs vecteurs de caractéristiques, sont stockés au format Parquet dans Amazon S3.

- le chargement des fichiers image depuis le compartiment S3.

Schéma du DataFrame après ajout de label.

```
root
|-- path: string (nullable = true)
|-- modificationTime: timestamp (nullable = true)
|-- length: long (nullable = true)
|-- content: binary (nullable = true)
|-- label: string (nullable = true)
```

```
+-----+-----+-----+-----+
|           path|  modificationTime|length|           content|
+-----+-----+-----+-----+
|s3://p8-data/Test...|2021-07-03 09:00:08| 7353|[FF D8 FF E0 00 1...|
|s3://p8-data/Test...|2021-07-03 09:00:08| 7350|[FF D8 FF E0 00 1...|
|s3://p8-data/Test...|2021-07-03 09:00:08| 7349|[FF D8 FF E0 00 1...|
|s3://p8-data/Test...|2021-07-03 09:00:08| 7348|[FF D8 FF E0 00 1...|
|s3://p8-data/Test...|2021-07-03 09:00:09| 7328|[FF D8 FF E0 00 1...|
+-----+-----+-----+-----+
only showing top 5 rows
```

- labelliser automatiquement les images en fonction des dossiers où elles sont situées.

```
+-----+-----+
|path                                     |label|
+-----+-----+
|s3://p8-data/Test/Watermelon/r_106_100.jpg|Watermelon|
|s3://p8-data/Test/Watermelon/r_109_100.jpg|Watermelon|
|s3://p8-data/Test/Watermelon/r_108_100.jpg|Watermelon|
|s3://p8-data/Test/Watermelon/r_107_100.jpg|Watermelon|
|s3://p8-data/Test/Watermelon/r_95_100.jpg |Watermelon|
+-----+-----+
only showing top 5 rows
```

3.1 MobileNetV2

Est une architecture de réseau de neurones convolutifs conçue pour des tâches de vision par ordinateur, comme la classification, la détection d'objets ou la segmentation d'images.


Principales caractéristiques :

- **Efficacité** : Il est conçu pour être léger et rapide, ce qui le rend adapté aux appareils avec des ressources limitées.
- **Précision élevée** : Malgré sa légèreté, il offre d'excellentes performances pour des tâches de vision complexes.
- **Préentraînement** : Le modèle est préentraîné sur des ensembles de données comme ImageNet.

Avantages :

Les vecteurs extraits par MobileNetV2 permettent de :

- Réduire la taille des données d'origine.
- Faciliter l'analyse en transformant des données visuelles en données numériques exploitables.
- Accélérer les calculs en aval, car les vecteurs de caractéristiques sont plus compacts que les images d'origine.



Limites potentielles

- Les performances dépendent fortement de la qualité du prétraitement des données.
- MobileNetV2 peut ne pas capturer certaines informations spécifiques si elles diffèrent beaucoup des données sur lesquelles il a été préentraîné (ImageNet).

3.2 Démonstration d'exécution du script PySpark sur le cloud

eu-west-3.console.aws.amazon.com/emr/home?region=eu-west-3#/clusterDetails/j-1VUHP3HV61XJG

Rechercher

Europe (Paris) | kourouma

Amazon EMR > EMR sur EC2: Clusters > projet-8-sekou-cluster1

Mis à jour il y a 5 minutes

Résilier

Cloner dans AWS CLI

Cloner

projet-8-sekou-cluster1

▼ Récapitulatif

Informations sur le cluster

ID de cluster
j-1VUHP3HV61XJG

Configuration de cluster
Groupes d'instances

Capacité
1 primaire(s) | 1 unité(s) principale(s) | 2 tâche(s)

Applications

Version d'Amazon EMR
emr-6.13.0

Applications installées
Hadoop 3.3.3, JupyterHub 1.5.0, Spark 3.4.1, TensorFlow 2.11.0

Gestion des clusters

Destination des journaux dans Amazon S3
aws-logs-545009849030-eu-west-3/elasticmapreduce

Interfaces utilisateur d'application persistantes
Serveur d'historique Spark
Serveur de chronologie YARN

DNS public du nœud primaire
ec2-13-36-234-229.eu-west-3.compute.amazonaws.com
Connexion au nœud primaire à l'aide de SSH
Connexion au nœud primaire à l'aide de SSM

Statut et heure

Statut
En attente

Heure de création
18 janvier 2025 16:04 (UTC+01:00)

Temps écoulé
12 minutes, 30 secondes

Propriétés

Actions d'amorçage

Instances (Matériel)

Étapes

Applications

Configurations

Surveillance

Évènements

Identifications (0)

Système d'exploitation

Version Amazon Linux : 2.0.20241217.0

Journaux de cluster

Archiver les fichiers journaux dans Amazon S3
Activé

Chiffrement pour les journaux
Désactivé

Emplacement Amazon S3
s3://aws-logs-545009849030-eu-west-3/elasticmapreduce/

Résiliation du cluster et remplacement des nœuds

Option de résiliation
Résilier automatiquement le cluster après le temps d'inactivité

Temps d'inactivité
20 minutes

Protection contre la résiliation
Désactivé

Remplacement des nœuds défectueux
Désactivé

Réseau et sécurité

Réseau

Configuration de sécurité

Autorisations

Propriétés

Actions d'amorçage

Instances (Matériel)

Étapes

Applications

Configurations

Surveillance

Évènements

Identifications (0)

Interfaces utilisateur d'application

Les applications installées sur votre cluster Amazon EMR publient des interfaces utilisateur en tant que sites web. Vous pouvez les utiliser pour surveiller l'activité du cluster.

Interfaces utilisateur d'application sur le cluster

Les interfaces utilisateur sur le cluster sont disponibles uniquement pendant l'exécution de votre cluster. Utilisez les liens suivants pour démarrer. Pour accéder à toutes les interfaces utilisateur d'application, configurez le tunneling SSH.

Interfaces utilisateur d'application persistantes

Les interfaces utilisateur persistantes ne nécessitent pas de tunneling SSH. Elles sont hébergées hors du cluster et sont disponibles pendant 30 jours après la fin d'une application.

Interfaces utilisateur d'application en direct

Ces interfaces utilisateur d'application sur cluster sont disponibles sans tunneling SSH.

Interfaces utilisateur d'application

Interface utilisateur du serveur d'historique Spark

Interfaces utilisateur d'application sur le nœud primaire

Celles-ci nécessitent l'activation du tunneling SSH.

Application	URL de l'interface utilisateur
Gestionnaire de ressources	http://ec2-13-36-234-229.eu-west-3.compute.amazonaws.com:8088/
JupyterHub	https://ec2-13-36-234-229.eu-west-3.compute.amazonaws.com:9443/
Nom du nœud HDFS	http://ec2-13-36-234-229.eu-west-3.compute.amazonaws.com:9870/
Serveur d'historique Spark	http://ec2-13-36-234-229.eu-west-3.compute.amazonaws.com:18080/

Activer une connexion SSH

Interface utilisateur d'application sur les nœuds principaux et nœuds de tâches

Application	URL de l'interface utilisateur
Gestionnaire de nœuds	http://ec2-000-000-000-000.compute-1.amazonaws.com:8042/
Nœud de données HDFS	http://ec2-000-000-000-000.compute-1.amazonaws.com:9864/

4. Conclusion

Objectifs atteints:

- La chaîne de traitement des données a été mise en place et validée pour la première version du moteur de classification des images de fruits.
- La réduction de dimension (PCA) a été correctement implémentée en PySpark pour améliorer l'efficacité du traitement des données et préparer l'architecture pour la gestion de grands volumes de données.

Architecture Big Data évolutive :

- Le projet a été conçu pour évoluer avec l'augmentation du volume des données, tout en utilisant l'infrastructure cloud AWS (EMR, S3, IAM) pour profiter de la scalabilité et des ressources distribuées.
- Les premières briques de l'architecture sont en place, et l'application mobile peut désormais sensibiliser le public tout en construisant un moteur de classification capable de traiter de grandes quantités d'images.

L'utilisation d'une infrastructure Big Data offre plusieurs bénéfices à "Fruits!", en particulier pour le traitement des données, l'amélioration des performances et l'adaptabilité à la croissance future.

- L'architecture permet une montée en charge fluide, avec la possibilité d'ajuster facilement la capacité du cluster selon les besoins.
- Bien que les coûts augmentent avec l'usage, ils demeurent bien inférieurs à ceux liés à l'achat de matériel ou à la location de serveurs dédiés.

Respect des contraintes RGPD et optimisation des coûts :

- L'instance EMR a été paramétrée pour garantir que les données soient traitées sur des serveurs situés sur le territoire européen, assurant ainsi la conformité avec le RGPD.
- L'utilisation raisonnée des ressources cloud et des tests sur des serveurs locaux permet de maintenir les coûts sous contrôle, respectant ainsi la contrainte de budget pour cette phase de développement.